

**TUGAS MACHINE LEARNING
ANALISIS & IMPLEMENTASI
DECISION TREE & NAIVE BAYES**



Disusun Oleh:

Abid Abdussalam G1A024073

Kelompok:

Rofid Fadhil G1A024065

Achmad Rifky Akbar G1A024091

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D IPP..

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU
2026**

Akses kode lengkap, dataset, dan seluruh keluaran. Laporan ini dibatasi maksimal 8 halaman sehingga hanya memuat tangkapan layar kode dan keluaran yang secara langsung mendukung poin-poin penilaian. Kode lengkap beserta hasil eksekusinya dapat diperiksa melalui notebook Google Colab: [Tugas1ML.ipynb – Google Colab](#). Seluruh berkas proyek dan kode juga tersedia pada [repositori GitHub kelompok](#). Dataset Mahasiswa_Lulus.xlsx merupakan data sintesis yang digunakan untuk keperluan pembelajaran dan tidak memuat data pribadi mahasiswa yang sebenarnya.

A. ANALISIS KONSEP

Analisis pada bagian ini membahas karakteristik dataset serta konsep dasar Decision Tree dan Naive Bayes sebagai dasar pemilihan model klasifikasi kelulusan mahasiswa. Dataset yang digunakan terdiri dari 500 data mahasiswa dengan tujuh fitur prediktor dan satu target Status_Kelulusan. Hasil eksplorasi menunjukkan bahwa terdapat 388 mahasiswa (77,6%) berstatus LULUS dan 112 mahasiswa (22,4%) berstatus TIDAK LULUS. Dataset tidak memiliki nilai kosong, sedangkan fitur terdiri atas variabel numerik dan kategorik yang perlu dipersiapkan sebelum pemodelan. Karakteristik tersebut menjadi dasar untuk membahas kesesuaian algoritma, asumsi independensi Naive Bayes, serta risiko overfitting pada Decision Tree.

Fitur	Tipe	Nilai / Sebaran	Missing
IPK	Numerik	0,00–4,00 (rata-rata 3,18; SD 0,70)	0
Kehadiran	Numerik	2–100 (rata-rata 87,98; SD 15,69)	0
Jam_Belajar	Numerik	0–10 jam/minggu (rata-rata 3,12; SD 1,65)	0
Organisasi	Kategorik	Yes (221); No (279)	0
Penghasilan_Ortu	Numerik	5.000–600.000 (rata-rata 59.116,51; SD 52.197,02)	0
Jenis_Kelamin	Kategorik	Male (300); Female (200)	0
Status_Basiswa	Kategorik	Yes (230); No (270)	0
Status_Kelulusan	Target	LULUS (388); TIDAK LULUS (112)	0

Tabel 1. Struktur dan ringkasan dataset mahasiswa (n = 500).

1. Kapan Decision Tree lebih cocok digunakan dibandingkan Naive Bayes?

Decision Tree lebih cocok digunakan ketika hubungan antara fitur dan target tidak sederhana serta melibatkan kombinasi beberapa kondisi. Pada prediksi kelulusan mahasiswa, faktor seperti IPK, Kehadiran, dan Jam_Belajar dapat memberikan informasi secara bersamaan. Decision Tree mampu membentuk aturan berdasarkan kombinasi tersebut melalui percabangan, sehingga pola keputusan dapat direpresentasikan dengan lebih fleksibel tanpa mengharuskan setiap fitur dianggap independen.

Selain fleksibel, Decision Tree memiliki kelebihan dari sisi interpretasi. Struktur pohon dapat divisualisasikan sehingga pihak kampus dapat melihat faktor dan kondisi yang digunakan dalam menghasilkan prediksi. Hal ini penting dalam konteks pendidikan karena hasil klasifikasi sebaiknya dapat dijelaskan kepada pihak yang berkepentingan. Naive Bayes lebih sederhana dan cepat, tetapi menggunakan asumsi independensi antarfitur yang belum tentu sesuai dengan karakteristik data mahasiswa.

2. Asumsi “independen” pada Naive Bayes

Naive Bayes mengasumsikan bahwa fitur-fitur prediktor relatif independen satu sama lain ketika kelas target telah diketahui. Dalam praktiknya, asumsi ini sering kali tidak sepenuhnya terpenuhi karena beberapa fitur dapat memberikan informasi yang saling berkaitan. Jika fitur yang berkorelasi diperlakukan sebagai informasi yang sepenuhnya terpisah, model dapat memberikan bobot probabilitas yang lebih kuat terhadap informasi yang sebenarnya saling tumpang tindih.

Pada dataset ini, pasangan yang secara konseptual berpotensi tidak independen adalah IPK–Jam_Belajar dan IPK–Kehadiran. Ketiganya sama-sama berkaitan dengan aktivitas dan pencapaian

akademik mahasiswa. Namun, berdasarkan data yang digunakan, hubungan tersebut tidak cukup kuat untuk menyatakan adanya ketergantungan yang sangat tinggi. Oleh karena itu, pasangan tersebut lebih tepat disebut berpotensi melanggar asumsi independensi, bukan sebagai bukti bahwa asumsi Naive Bayes pasti dilanggar. Dampak akhirnya terhadap performa GaussianNB tetap perlu dilihat melalui hasil evaluasi model pada Bagian B.

3. Apa risiko overfitting pada Decision Tree dan bagaimana mengatasinya?

Decision Tree berisiko mengalami overfitting apabila pohon berkembang terlalu kompleks dan terlalu menyesuaikan diri dengan data training. Risiko ini terlihat pada model `max_depth=None`, yang dapat membuat banyak percabangan hingga mengikuti pola yang sangat spesifik pada data training. Berdasarkan hasil pengujian, model tersebut memperoleh akurasi training 100%, tetapi akurasi testing hanya 80%. Perbedaan ini menunjukkan bahwa model sangat baik dalam mempelajari data training, tetapi kemampuan generalisasinya lebih rendah ketika menghadapi data yang belum pernah dilihat.

Salah satu cara mengurangi risiko tersebut adalah membatasi kompleksitas pohon menggunakan parameter `max_depth`. Pada tugas ini digunakan `max_depth=3` sebagai model dengan struktur yang lebih sederhana. Model tersebut memperoleh akurasi training 91,25% dan testing 90%, sehingga kesenjangan antara performa training dan testing jauh lebih kecil dibandingkan `max_depth=None`. Selain `max_depth`, overfitting juga dapat dikendalikan menggunakan `min_samples_split` atau `min_samples_leaf`. Dengan demikian, pemilihan model sebaiknya mempertimbangkan kemampuan generalisasi, bukan hanya performa pada data training.

B. IMPLEMENTASI DAN EVALUASI

Bagian ini berfokus pada implementasi dan evaluasi tiga model klasifikasi, yaitu Decision Tree dengan `max_depth=3`, Decision Tree dengan `max_depth=None`, dan Gaussian Naive Bayes (GaussianNB). Sebelum pemodelan, dataset melalui tahap preprocessing yang meliputi pemeriksaan missing value, encoding fitur kategorik, serta pembagian data menjadi data training dan testing dengan proporsi 80:20. Selanjutnya, ketiga model dibandingkan menggunakan Accuracy, Precision, Recall, dan F1-Score serta confusion matrix. Hasil evaluasi kemudian divisualisasikan dan digunakan untuk menganalisis kesalahan prediksi sebagai dasar dalam menentukan model yang paling sesuai untuk kasus prediksi kelulusan mahasiswa.

1. Preprocessing

Tahap preprocessing dilakukan untuk memastikan data dapat digunakan oleh algoritma klasifikasi. Dataset terlebih dahulu diperiksa menggunakan `isnull()` dan hasilnya menunjukkan bahwa seluruh fitur memiliki 0 missing value, sehingga tidak diperlukan proses imputasi. Variabel target `Status_Kelulusan` dipisahkan dari fitur prediktor, kemudian kelas LULUS dipetakan menjadi 1 dan TIDAK LULUS menjadi 0. Sementara itu, fitur kategorik Organisasi, Jenis_Kelamin, dan Status_Basiswa diubah menjadi bentuk numerik menggunakan one-hot encoding. Setelah proses tersebut, data memiliki 10 fitur numerik yang digunakan dalam pemodelan.

Data kemudian dibagi menjadi 80% data training dan 20% data testing menggunakan `train_test_split` dengan `random_state=42` dan `stratify=y`. Hasil pembagian menghasilkan 400 data training dan 100 data testing. Penggunaan stratify bertujuan mempertahankan proporsi kelas target pada data training dan testing sehingga evaluasi model menjadi lebih representatif.

Tahap	Hasil
Jumlah data	500

Missing value	0
Data training	400(80%)
Data testing	100(20%)
Jumlah fitur setelah encoding	10
random_state	42
Strafikasi	Ya

Tabel 2. Hasil preprocessing dan pembagian dataset.

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

print("Data training:", X_train.shape)
print("Data testing:", X_test.shape)

*** Data training: (400, 10)
Data testing: (100, 10)
```

Gambar 1. Ukuran data training dan data testing setelah proses pembagian dataset.

2. Modeling

Tiga model klasifikasi dibangun untuk membandingkan pendekatan berbasis pohon keputusan dan probabilistik. Model pertama adalah Decision Tree dengan `max_depth=3`, yang membatasi kedalaman pohon agar struktur model tetap sederhana. Model kedua adalah Decision Tree dengan `max_depth=None`, sehingga pohon dapat berkembang tanpa batas kedalaman yang ditentukan. Model ketiga adalah Gaussian Naive Bayes (GaussianNB) sebagai model pembanding berbasis probabilitas. Ketiga model dilatih menggunakan data training dan kemudian digunakan untuk memprediksi data testing.

Perbandingan dua konfigurasi Decision Tree digunakan untuk melihat pengaruh kompleksitas pohon terhadap performa prediksi. Sementara itu, GaussianNB memberikan pembanding dengan pendekatan yang berbeda dari Decision Tree. Dengan menggunakan tiga model tersebut, performa dapat dibandingkan berdasarkan Accuracy, Precision, Recall, dan F1-Score.

3. Evaluasi

Evaluasi dilakukan menggunakan empat metrik, yaitu Accuracy, Precision, Recall, dan F1-Score. Hasil pengujian pada 100 data testing menunjukkan bahwa Decision Tree dengan `max_depth=3` menghasilkan performa keseluruhan paling tinggi. Model tersebut memperoleh Accuracy 90,00%, Precision 92,50%, Recall 94,87%, dan F1-Score 93,67%.


	Model	Accuracy	Precision	Recall	F1-Score
0	Decision Tree <code>max_depth=3</code>	0.90	0.925000	0.948718	0.936709
1	Decision Tree <code>max_depth=None</code>	0.80	0.891892	0.846154	0.868421
2	Gaussian Naive Bayes	0.85	0.846154	0.987179	0.911243

Gambar 2. Perbandingan performa tiga model pada data testing.

GaussianNB memiliki Recall tertinggi sebesar 98,72%, yang menunjukkan bahwa model tersebut sangat baik dalam mengenali mahasiswa yang termasuk kelas LULUS. Namun, Precision GaussianNB hanya 84,62%, lebih rendah dibandingkan Decision Tree `max_depth=3`. Sementara itu, Decision Tree `max_depth=None` menghasilkan nilai terendah pada Accuracy dan F1-Score. Berdasarkan keempat metrik secara keseluruhan, Decision Tree `max_depth=3` memberikan performa yang paling seimbang.

Confusion Matrix

Confusion matrix digunakan untuk melihat jumlah prediksi benar dan salah pada masing-masing kelas. Berikut tiga output confusion matrix dari masing-masing model yang digunakan, yaitu Decision Tree `max_depth=3`, Decision Tree `max_depth=None`, dan GaussianNB.



Gambar 3. Confusion matrix tiga model pada data testing.

Model	TN	FP	FN	TP	Total Benar	Total Salah
Decision Tree max_depth=3	16	6	4	74	90	10
Decision Tree max_depth=None	14	8	12	66	80	20
GaussianNB	8	14	1	77	85	15


Tabel 3. Analisis confusion matrix

Berdasarkan confusion matrix, Decision Tree max_depth=3 memberikan keseimbangan terbaik antara kemampuan mengenali kelas LULUS dan TIDAK LULUS. Model ini menghasilkan 74 TP dan 16 TN dengan hanya 10 kesalahan, terdiri atas 6 FP dan 4 FN. Decision Tree max_depth=None menghasilkan kesalahan paling banyak, yaitu 20 data, terutama karena jumlah FN mencapai 12 data. Sementara itu, GaussianNB memiliki jumlah TP tertinggi, yaitu 77, dan FN terendah, yaitu hanya 1 data. Kondisi tersebut menjelaskan mengapa GaussianNB memperoleh recall tertinggi sebesar 98,71%. Namun, GaussianNB juga menghasilkan 14 FP sehingga precision-nya lebih rendah. Dengan demikian, apabila tujuan utama adalah memperoleh performa yang seimbang pada kedua kelas, Decision Tree max_depth=3 lebih sesuai, sedangkan GaussianNB dapat dipertimbangkan apabila prioritas utama adalah meminimalkan mahasiswa yang sebenarnya LULUS tetapi diprediksi TIDAK LULUS.

4. Visualisasi

a. Plot Pohon Keputusan


Visualisasi Decision Tree dilakukan pada model dengan max_depth=3. Pohon menunjukkan proses pengambilan keputusan berdasarkan fitur-fitur hasil preprocessing. Pembatasan kedalaman menjadi tiga membuat struktur pohon lebih sederhana sehingga aturan prediksi lebih mudah dibaca dan dijelaskan. Notebook kalian memang sudah menggunakan plot_tree() dengan feature_names, nama kelas, serta tampilan pohon yang diperjelas.



Gambar 4. Visualisasi Decision Tree dengan max_depth=3.

b. Bar Chart Perbandingan Metrik


Bar chart digunakan untuk membandingkan Accuracy, Precision, Recall, dan F1-Score dari ketiga model. Visualisasi ini menunjukkan bahwa Decision Tree max_depth=3 memiliki performa paling seimbang, sedangkan GaussianNB memiliki Recall tertinggi. Decision Tree max_depth=None cenderung memiliki nilai metrik lebih rendah dibandingkan kedua model lainnya.



Gambar 5. Perbandingan Accuracy, Precision, Recall, dan F1-Score tiga model.

5. Analisis Error

Analisis error dilakukan dengan mengambil lima data pertama yang mengalami kesalahan prediksi pada Decision Tree max_depth=3. Notebook menunjukkan bahwa kelima data tersebut memiliki nilai aktual 0 (TIDAK LULUS) tetapi diprediksi sebagai 1 (LULUS). Data yang dianalisis memiliki indeks 19, 263, 475, 110, dan 160.



Gambar 6. Lima sampel data yang salah diprediksi oleh Decision Tree max_depth=3.

Kelima kasus tersebut menunjukkan bahwa model cenderung memberikan prediksi LULUS meskipun beberapa karakteristik akademiknya relatif rendah. Misalnya, indeks 19 memiliki IPK 3,15, kehadiran 90, dan dua jam belajar, tetapi aktualnya TIDAK LULUS. Pada indeks 263, kehadiran bahkan mencapai 100, tetapi IPK 2,94 dan jam belajar hanya satu jam. Hal ini menunjukkan bahwa kombinasi fitur yang tersedia belum selalu cukup untuk membedakan kedua kelas secara sempurna. Kemungkinan terdapat faktor lain yang tidak tersedia dalam dataset, seperti kondisi akademik tertentu atau faktor pribadi mahasiswa, yang turut memengaruhi status kelulusan.

Kesalahan tersebut juga memperlihatkan bahwa hasil model sebaiknya tidak digunakan sebagai keputusan tunggal mengenai kelulusan mahasiswa. Model dapat digunakan untuk memberikan indikasi awal atau membantu pihak kampus mengidentifikasi mahasiswa yang membutuhkan perhatian lebih lanjut, tetapi keputusan akhir tetap perlu mempertimbangkan informasi lain di luar fitur yang digunakan dalam model.

C. REKOMENDASI & ETIKA

Bagian ini membahas pemilihan model berdasarkan hasil evaluasi, potensi bias dalam penggunaan fitur mahasiswa, serta simulasi prediksi untuk melihat bagaimana model mengambil

keputusan pada kondisi mahasiswa dengan karakteristik yang berbeda. Analisis tidak hanya mempertimbangkan nilai metrik, tetapi juga interpretabilitas, risiko kesalahan, dan dampak penggunaan model dalam konteks pendidikan.

1. Rekomendasi Model

Berdasarkan hasil evaluasi pada data testing, Decision Tree dengan max_depth=3 direkomendasikan sebagai model yang paling sesuai untuk membantu memprediksi kelulusan mahasiswa. Model ini memperoleh Accuracy sebesar 90,00%, Precision 92,50%, Recall 94,87%, dan F1-Score 93,67%. Dibandingkan Decision Tree max_depth=None dan GaussianNB, model ini memberikan performa yang paling seimbang pada empat metrik evaluasi. GaussianNB memang memiliki Recall lebih tinggi, yaitu 98,72%, tetapi memiliki Accuracy dan Precision yang lebih rendah.

Pemilihan max_depth=3 juga mempertimbangkan kemampuan generalisasi dan interpretasi model. Pohon yang lebih sederhana lebih mudah dijelaskan kepada pihak kampus dan tidak menunjukkan kompleksitas berlebihan seperti Decision Tree tanpa batas kedalaman. Oleh karena itu, model ini lebih tepat digunakan sebagai alat bantu untuk mengidentifikasi mahasiswa yang berpotensi mengalami masalah kelulusan, bukan sebagai penentu tunggal keputusan akademik. Prediksi model tetap perlu dikombinasikan dengan evaluasi dan pertimbangan dari pihak akademik.

Model	Accuracy	Precision	Recall	F1-Score
Decision Tree max_depth=3	90,00%	92,50%	94,87%	93,67%
Decision Tree max_depth=None	80,00%	89,19%	84,62%	86,84%
GaussianNB	98,72%	84,62%	98,72%	91,12%

Tabel 4. Perbandingan performa tiga model pada data testing.

2. Bias & Etika

Penggunaan fitur Penghasilan_Ortu dan Jenis_Kelamin dalam model perlu diperhatikan karena kedua fitur tersebut dapat berpotensi menghasilkan keputusan yang tidak adil apabila pola pada data historis mengandung bias. Penghasilan orang tua berkaitan dengan kondisi sosial-ekonomi mahasiswa. Jika digunakan untuk keputusan seperti beasiswa, mahasiswa dari kelompok ekonomi tertentu dapat memperoleh perlakuan berbeda bukan berdasarkan kebutuhan atau prestasi mereka secara langsung, tetapi berdasarkan pola yang dipelajari model. Demikian pula, penggunaan Jenis_Kelamin berisiko membuat model menghasilkan perbedaan prediksi antar kelompok apabila terdapat pola historis yang tidak representatif.

Risiko tersebut dapat dimitigasi dengan membatasi penggunaan fitur sensitif untuk keputusan yang berdampak langsung terhadap mahasiswa. Sebelum model diterapkan, kampus perlu melakukan evaluasi performa berdasarkan kelompok, misalnya membandingkan tingkat kesalahan prediksi berdasarkan jenis kelamin dan kelompok kondisi ekonomi. Selain itu, model sebaiknya digunakan sebagai alat bantu, disertai pemeriksaan manusia dan mekanisme keberatan atau peninjauan ulang apabila mahasiswa merasa hasil keputusan tidak sesuai. Untuk keputusan beasiswa, faktor seperti kondisi ekonomi dan prestasi sebaiknya dinilai menggunakan kriteria yang transparan dan relevan, bukan hanya berdasarkan prediksi model.

3. Simulasi

Simulasi dilakukan pada mahasiswa dengan IPK tinggi sebesar 3,80, tetapi memiliki Kehadiran rendah sebesar 50% dan Jam_Belajar hanya 4 jam per minggu. Hasil pengujian menunjukkan bahwa

ketiga model, yaitu Decision Tree dengan max_depth=3, Decision Tree dengan max_depth=None, dan GaussianNB, sama-sama memprediksi mahasiswa tersebut TIDAK LULUS.

Hasil tersebut menunjukkan bahwa IPK yang tinggi tidak selalu cukup untuk menghasilkan prediksi LULUS. Dalam data yang digunakan, model mempertimbangkan beberapa fitur secara bersama-sama, sehingga Kehadiran yang rendah dan Jam_Belajar yang relatif sedikit dapat menjadi sinyal kuat terhadap risiko tidak lulus tepat waktu. Decision Tree mengambil keputusan berdasarkan aturan pemisahan fitur yang terbentuk selama pelatihan, sedangkan GaussianNB menghitung probabilitas berdasarkan distribusi masing-masing fitur pada setiap kelas. Meskipun mekanisme keduanya berbeda, pada kasus simulasi ini keduanya memberikan kesimpulan yang sama karena kombinasi karakteristik mahasiswa lebih mendukung kelas TIDAK LULUS.

Model	Prediksi
Decision Tree (max_depth=3)	TIDAK LULUS
Decision Tree (max_depth=None)	TIDAK LULUS
GaussianNB	TIDAK LULUS

Tabel 5. Hasil simulasi prediksi mahasiswa dengan IPK tinggi dan Kehadiran rendah

PROFIL MAHASISWA SIMULASI										
IPK	Kehadiran	Jam_Belajar	Penghasilan_Ortu	Organisasi_No	Organisasi_Yes	Jenis_Kelamin_Female	Jenis_Kelamin_Male	Status_Beasiswa_No	Status_Beasiswa_Yes	
0	3.8	50	4	50000	1	0	0	1	1	0

HASIL PREDIKSI		
	Model	Prediksi
0	Decision Tree (max_depth=3)	TIDAK LULUS
1	Decision Tree (max_depth=None)	TIDAK LULUS
2	GaussianNB	TIDAK LULUS

Gambar 5. Output simulasi prediksi mahasiswa dengan IPK tinggi dan Kehadiran rendah pada Google Colab.

Kesimpulan

Berdasarkan hasil analisis dan implementasi, tugas ini menerapkan *machine learning* untuk memprediksi kelulusan tepat waktu mahasiswa menggunakan Decision Tree dan Gaussian Naive Bayes. CPL-3 dicapai melalui penerapan kedua algoritma, sedangkan CPL-5 melalui analisis asumsi independensi, *overfitting*, performa, dan kesalahan prediksi. CPL-7 diwujudkan melalui penyajian tabel, visualisasi, *confusion matrix*, dan interpretasi hasil. Sejalan dengan CPMK-4, tiga model berhasil dibangun, yaitu Decision Tree max_depth=3, Decision Tree max_depth=None, dan GaussianNB. Pada 100 data uji, Decision Tree max_depth=3 memberikan hasil terbaik dengan akurasi 90%, precision 92,5%, recall 94,87%, dan F1-Score 93,67%.

Berdasarkan CPMK-5, Decision Tree max_depth=3 direkomendasikan karena memiliki performa tertinggi dan struktur yang mudah diinterpretasikan. Decision Tree max_depth=None memperoleh akurasi 80%, sedangkan GaussianNB 85% dengan recall tertinggi 98,71%. *Confusion matrix* menunjukkan masing-masing model menghasilkan 10, 20, dan 15 kesalahan. Penggunaan model tetap perlu memperhatikan *overfitting*, ketergantungan antarfitur, serta potensi bias pada Penghasilan_Ortu dan Jenis_Kelamin. Pada simulasi mahasiswa dengan IPK 3,80 dan Kehadiran 50%, ketiga model memprediksi TIDAK LULUS, menunjukkan bahwa IPK tinggi tidak selalu menentukan kelulusan tepat waktu.